

Clasificación de tumores cerebrales

AGATA CAVIGIOLI, GIOVANNI SGAMBATO

La clasificación precisa de imágenes de tumores cerebrales representa un desafío significativo en la práctica médica, con implicaciones críticas para el diagnóstico y tratamiento de pacientes. En este proyecto, se enfoca en emplear redes neuronales convolucionales (CNN) para abordar esta tarea específica. El conjunto de datos utilizado en este estudio comprende tres categorías distintas de tumores cerebrales: Glioma, Meningioma y Tumor Hipofisario. La diferenciación precisa entre estas categorías es fundamental para una intervención médica precisa y oportuna. Para lograr este objetivo, se ha llevado a cabo un riguroso proceso experimental que involucra la implementación y evaluación de diversas arquitecturas de redes neuronales. Estos experimentos se han diseñado meticulosamente para evaluar el rendimiento de las CNN en la clasificación de imágenes de tumores cerebrales. Además, se han incorporado estrategias variadas de evaluación para garantizar una comprensión exhaustiva del desempeño de cada arquitectura propuesta. Este artículo busca presentar de manera detallada los resultados y conclusiones obtenidos de estos experimentos. El objetivo es ofrecer una evaluación objetiva y precisa del potencial, así como de las limitaciones identificadas en el uso de redes neuronales convolucionales para la clasificación de imágenes de tumores cerebrales. Este análisis contribuye al entendimiento actual del desempeño de estas arquitecturas en un contexto clínico, sin perder de vista la necesidad de seguir explorando nuevas estrategias y enfoques en esta área de investigación.

1. REDES Y CONFIGURACIONES UTILIZADAS

En el marco de este ejercicio, se procedió a la implementación de múltiples modelos con el fin de abordar la clasificación de tumores cerebrales y realizar una comparativa exhaustiva de sus resultados.

En primer lugar, se llevó a cabo una comparación directa entre una red neuronal completamente conectada y una red neuronal convolucional, evaluando su desempeño en la tarea de clasificación.

Además, se exploró la utilización de la arquitectura ResNet18 desde una inicialización aleatoria de pesos para determinar su idoneidad en la clasificación de imágenes de tumores cerebrales. Asimismo, se empleó la versión pre-entrenada

de ResNet18, adaptándola al conjunto de datos específico de tumores cerebrales mediante transfer learning, con el propósito de evaluar su capacidad en esta tarea particular.

Cabe destacar que se realizaron ajustes en los parámetros de cada modelo con el objetivo de reducir el sobreajuste y mejorar la generalización de los resultados.

2. CONFIGURACIÓN DE LAS PRUEBAS


Training Set:
Number of images: 2757
Dimensions and their count:
Dimensions: (256, 256), Count: 2757
Test Set:
Number of images: 307
Dimensions and their count:
Dimensions: (256, 256), Count: 307

Dentro del proceso de evaluación de modelos de aprendizaje automático, se enfatizó la importancia de una configuración precisa de los conjuntos de datos utilizados para entrenamiento y prueba. Se realizó una subdivisión del conjunto de imágenes de tumores cerebrales en dos partes esenciales: una destinada al entrenamiento de los modelos y otra reservada para evaluar su desempeño en datos no empleados durante el entrenamiento.

Para garantizar la idoneidad de los datos de entrada, se llevaron a cabo transformaciones fundamentales en las imágenes antes de la fase de entrenamiento. Estas transformaciones incluyeron la normalización del tamaño de las imágenes a una resolución uniforme de 256x256 píxeles y su conversión a formato tensorial, facilitando así un procesamiento más eficiente por parte de los modelos.

En términos de la metodología de entrenamiento, se estableció un tamaño de lote consistente de 256 muestras para ambos conjuntos de datos utilizados en esta evaluación. Esta decisión fue crucial para mantener una coherencia en el procesamiento y la evaluación de los modelos, garantizando una comparación justa de su rendimiento.

Shape of X [N, C, H, W]: torch.Size([32, 1, 256, 256])
Number of Labels: 32



3. PARÁMETROS DE ENTRENAMIENTO

El proceso de entrenamiento de la red neuronal es un factor determinante para obtener resultados precisos en la clasificación. Durante la experimentación, se exploraron distintas configuraciones y parámetros, entre los cuales se destacan:

La Función de Pérdida: Se empleó la función de pérdida de entropía cruzada (Cross Entropy Loss) durante el entrenamiento. Esta métrica es reconocida por su idoneidad en problemas de clasificación multiclase, permitiendo cuantificar la discrepancia entre las predicciones del modelo y las etiquetas reales de las imágenes.

El Optimizador: Para la actualización de los pesos de la red neuronal, se optó por el uso del optimizador Adam. Esta elección se fundamenta en su eficiencia y su capacidad para adaptarse bien a diversas tasas de aprendizaje, siendo específicamente empleada con una tasa de aprendizaje establecida en 0.001.


Épocas: En el transcurso del ejercicio de entrenamiento, se llevaron a cabo un total de 8 épocas. Cada época representa un ciclo completo a través de todo el conjunto de entrenamiento, permitiendo que el modelo aprenda de los datos repetidamente para mejorar su capacidad de generalización.

4. GRÁFICAS DE PÉRDIDA Y PRECISIÓN

Esta sección analiza los resultados obtenidos por diferentes arquitecturas de redes neuronales implementadas en el estudio: FC (Fully Connected), CNN1, CNN2, CNN3 y ResNet18. Se presentarán gráficas que ilustran la evolución de la pérdida y la precisión a lo largo del entrenamiento de cada modelo. Estos gráficos proporcionan una visión detallada del rendimiento de cada arquitectura, permitiendo comparar cómo cada una de ellas aborda la clasificación de imágenes de tumores cerebrales. Se profundizará en las tendencias de convergencia, posibles puntos de sobreajuste y el desempeño relativo entre las diferentes redes neuronales implementadas. Estas visualizaciones son fundamentales para comprender el comportamiento y la eficacia de cada modelo durante el proceso de entrenamiento, brindando insights cruciales para la selección y mejora de arquitecturas en aplicaciones de clasificación de imágenes médicas.

A. Fully Connected (FC)

Las redes totalmente conectadas son modelos clásicos donde cada neurona de una capa está conectada a todas las de la siguiente, lo que les otorga gran capacidad de aprendizaje en conjuntos de datos pequeños. Sin embargo, en imágenes, suelen requerir una cantidad masiva de parámetros, volviéndose menos eficientes y propensas al sobreajuste.



Esta red neuronal parece estar mejorando con cada época. Comenzó con una precisión del 57.89 en el conjunto de entrenamiento y del 68.1 en el conjunto de prueba en la primera época, y luego vimos un aumento gradual en la precisión en ambas medidas a lo largo de las siguientes épocas. Llegó a alcanzar una precisión del 71.45 en el conjunto de entrenamiento y del 73.9 en el conjunto de prueba en la época 7.


En cuanto a las capacidades de esta red, muestra un progreso considerable en la capacidad de generalización, ya que la precisión en el conjunto de prueba está mejorando a medida que avanza el entrenamiento. Sin embargo, la brecha entre la precisión en el entrenamiento y en el conjunto de prueba se mantiene, lo que sugiere que podría haber algo de sobreajuste, especialmente visto en la ligera caída en la precisión del conjunto de prueba en la última época.

En resumen, esta red neuronal muestra mejoras significativas en su capacidad para aprender y generalizar a lo largo de las épocas, aunque podría beneficiarse de técnicas adicionales para reducir el sobreajuste y mejorar la precisión en el conjunto de prueba.

B. CNN3

Esta arquitectura de red neuronal convolucional (CNN) consta de tres capas convolucionales seguidas por capas de agrupación y capas totalmente conectadas al final. Puede ser una versión simplificada de una CNN con un número moderado de filtros y capas. Tiene una arquitectura más profunda y usa técnicas de

dropout para evitar el sobreajuste.



Esta segunda red neuronal muestra un rendimiento impresionante en términos de precisión y pérdida. Comenzando con una precisión de entrenamiento del 70.4 y una precisión de prueba del 67.8 en la primera época, esta red experimentó un crecimiento excepcional en la precisión en cada época subsiguiente. Al finalizar en la octava época, alcanzó una asombrosa precisión de entrenamiento del 96.08 y una precisión de prueba del 90.2.


En cuanto a la pérdida, la red comenzó con una pérdida alta tanto en entrenamiento como en prueba en la primera época, pero logró reducir drásticamente esta pérdida a lo largo del entrenamiento. Al finalizar, alcanzó una pérdida de entrenamiento de 0.003105 y una pérdida de prueba de 0.403698.

Esta red muestra una capacidad excepcional para aprender patrones en los datos de entrenamiento, logrando una precisión notablemente alta en el conjunto de prueba, lo que sugiere una excelente capacidad de generalización.

Comparando ambas redes, la segunda red muestra un rendimiento notablemente superior en términos de precisión y pérdida en el conjunto de prueba. La segunda red supera significativamente a la primera en términos de capacidad para aprender y generalizar a partir de los datos, mostrando una mejora significativa en la precisión y una reducción sustancial en la pérdida en el conjunto de prueba.


C. ResNet18 y Transfer Learning

La ResNet18 es una arquitectura de red neuronal convolucional preentrenada diseñada para tareas de clasificación de imágenes. El "transfer learning" es una técnica donde se aprovecha el conocimiento aprendido por una red en un conjunto de datos para aplicarlo a otro conjunto de datos diferente.



La red muestra un patrón de sobreajuste. A lo largo del entrenamiento, mejora constantemente en los datos de entrenamiento, pero esa mejora no se refleja en los datos de prueba, donde la precisión se mantiene baja y estable alrededor del 46.6 al 47.2. Esto indica que la red está aprendiendo detalles específicos de los datos de entrenamiento en lugar de patrones generales, lo que limita su capacidad para generalizar a nuevos datos.

Los cambios realizados buscan abordar el sobreajuste y afinar el modelo ResNet18 para lograr una mejor generalización. En resumen, se ajustó la capa completamente conectada (clasificador) agregando capas lineales adicionales, activaciones no lineales y técnicas como Batch Normalization y Dropout para evitar el sobreajuste. Además, se realizó un ajuste fino en ResNet18, descongelando ciertas capas para permitirles adaptarse más al conjunto de datos específico. Se implementaron diferentes tasas de aprendizaje para estas capas con el objetivo de controlar cómo se adaptan a los datos, ayudando así a mejorar la capacidad de la red para aprender características relevantes y prevenir el sobreajuste. Estos cambios buscan equilibrar la utilización de las características preentrenadas de ResNet18 con la adaptación del modelo a un nuevo conjunto de datos, con la esperanza de mejorar su capacidad para generalizar y evitar el sobreajuste.



Durante las primeras épocas, la precisión y la pérdida promedio en el conjunto de entrenamiento y prueba varían significativamente.

En la primera época, la red muestra una precisión del 67.25 en el conjunto de entrenamiento, pero en el conjunto de prueba, la precisión es del 0.0. Esto indica una gran discrepancia entre la capacidad de la red para ajustarse a los datos de entrenamiento y su incapacidad para generalizar a datos nuevos.

A medida que avanza el entrenamiento, la precisión en el conjunto de entrenamiento mejora hasta alcanzar alrededor del 91.69 en la última época. Sin embargo, la precisión en el conjunto de prueba no mejora de manera significativa y varía alrededor del 40-60, lo que sugiere que la red sigue teniendo dificultades para generalizar.

La pérdida promedio en el conjunto de prueba también se mantiene relativamente alta y fluctúa, indicando que la red sigue aprendiendo detalles específicos de los datos de entrenamiento en lugar de patrones generales que se apliquen a nuevos datos.

A pesar de los ajustes para reducir el sobreajuste, como el uso de técnicas como Dropout y Batch Normalization, así como el ajuste fino de la red preentrenada, la red aún muestra dificultades para generalizar a datos no vistos, lo que sugiere que pueden ser necesarios más ajustes o técnicas adicionales para mejorar su capacidad de generalización.

5. COMPARACIÓN ENTRE ESTRATEGIAS

Analicemos las estrategias empleadas en las diferentes arquitecturas de redes neuronales implementadas.

Red Neuronal Totalmente Conectada (FC):

Rendimiento: La red muestra mejoras notables en precisión a lo largo de las épocas tanto en entrenamiento como en prueba, aunque la brecha entre la precisión de entrenamiento y prueba

sugiere cierto sobreajuste.

Capacidades: Si bien muestra mejoras en la generalización, aún hay espacio para reducir el sobreajuste y mejorar la precisión en el conjunto de prueba.

CNN3:

Rendimiento: Esta red exhibe un rendimiento sobresaliente desde el inicio, con una mejora notable en la precisión tanto en entrenamiento como en prueba a lo largo de las épocas.

Capacidades: Demuestra una excelente capacidad para aprender patrones en los datos de entrenamiento y generalizar eficientemente, presentando una alta precisión en el conjunto de prueba.

ResNet18 con Transfer Learning y Ajustes:

Rendimiento: A pesar de los ajustes para reducir el sobreajuste y mejorar la generalización, la red todavía muestra dificultades para generalizar a nuevos datos, reflejado por la brecha persistente entre la precisión de entrenamiento y prueba.

Capacidades: Aunque se realizaron ajustes significativos y fine-tuning, la red aún presenta desafíos para generalizar a datos no vistos, indicando la necesidad de más ajustes o técnicas adicionales.

En comparación, la red CNN3 parece superar significativamente a la FC y a la versión ajustada de ResNet18 en términos de precisión y capacidad de generalización en el conjunto de prueba. Mientras que la FC muestra mejoras graduales y ResNet18 con ajustes aún lucha por generalizar, la CNN3 demuestra una capacidad excepcional para aprender y adaptarse a los datos, lo que resulta en una alta precisión en el conjunto de prueba.

La CNN3 podría considerarse la arquitectura más efectiva entre las evaluadas, seguida por la FC y luego por la ResNet18 ajustada, en función de su capacidad para abordar el sobreajuste y su rendimiento en la clasificación de imágenes de tumores cerebrales.

6. CONCLUSIONES Y LÍNEAS DE MEJORA:

En este estudio comparativo de varias arquitecturas de redes neuronales para la clasificación de imágenes de tumores cerebrales, se observó que la red CNN3 mostró un rendimiento destacado, superando significativamente a la red totalmente conectada (FC) y a la ResNet18 ajustada en términos de precisión y capacidad de generalización. La FC demostró mejoras graduales y una necesidad de reducir el sobreajuste, mientras que la ResNet18 con ajustes todavía luchó por generalizar a nuevos datos a pesar de las modificaciones realizadas. Para futuras investigaciones, se sugiere explorar estrategias adicionales para mejorar la generalización de la ResNet18, como la implementación de más técnicas de regularización o la búsqueda de hiperparámetros óptimos. Además, considerar el uso de conjuntos de datos más amplios y diversos podría ayudar a evaluar más exhaustivamente el rendimiento de las diferentes arquitecturas de redes neuronales en esta tarea de clasificación específica.